

NGHIÊN CỨU ỨNG DỤNG VÀ TÍNH CHÍNH MÔ HÌNH NGÔN NGỮ LỚN (LLM) TRONG TỰ ĐỘNG HÓA GIẢI BÀI TẬP XÁC SUẤT – THỐNG KÊ

TS. Trần Thị Hoàng Yến, Trần Đức Lương, Lưu Nhật Nam, Lê Đình Tùng, Nguyễn Trần Quang Minh

Khoa Khoa học Ứng dụng, Trường Đại học Kinh tế - Kỹ thuật Công nghiệp

Đến Tòa soạn ngày .../.../2026, chấp nhận đăng ngày .../.../2026

Tóm tắt: Sự phát triển của trí tuệ nhân tạo tạo sinh và các mô hình ngôn ngữ lớn đã mở ra nhiều cơ hội ứng dụng trong giáo dục. Tuy nhiên, đa số mô hình hiện nay chủ yếu được huấn luyện trên dữ liệu tiếng Anh, nên còn hạn chế khi xử lý các bài toán học thuật bằng tiếng Việt, đặc biệt là bài toán Xác suất – Thống kê. Bài báo này nghiên cứu ứng dụng và tinh chỉnh một mô hình ngôn ngữ lớn mã nguồn mở nhằm hỗ trợ tự động hóa quá trình giải dạng toán này. Phương pháp nghiên cứu gồm xây dựng bộ dữ liệu lời giải theo từng bước, áp dụng PEFT và LoRA để tinh chỉnh mô hình, đồng thời sử dụng LLM-as-a-Judge để đánh giá tính đúng đắn và logic của lời giải. Kết quả cho thấy mô hình sau tinh chỉnh tạo được lời giải có cấu trúc rõ ràng và cho độ chính xác cao hơn mô hình gốc. Nghiên cứu góp phần đề xuất một hướng tiếp cận hiệu quả cho bài toán giải toán tiếng Việt bằng LLM.

I. Đặt vấn đề

Trong những năm gần đây, sự phát triển mạnh mẽ của trí tuệ nhân tạo tạo sinh (Generative Artificial Intelligence) và các mô hình ngôn ngữ lớn (Large Language Models – LLMs) đã mở ra nhiều cơ hội ứng dụng trong nhiều lĩnh vực, đặc biệt là giáo dục. Các mô hình như GPT, Gemma, LLaMA và DeepSeek cho thấy khả năng xử lý ngôn ngữ tự nhiên và suy luận ở mức cao, từ đó hỗ trợ hiệu quả cho các tác vụ như tóm tắt văn bản, trả lời câu hỏi và hỗ trợ học tập.

Trong giáo dục toán học, việc ứng dụng trí tuệ nhân tạo để hỗ trợ giải bài tập và giải thích lời giải đang trở thành một hướng nghiên cứu quan trọng. Tuy nhiên, phần lớn các hệ thống hiện nay được xây dựng chủ yếu trên dữ liệu tiếng Anh, nên còn nhiều hạn chế khi áp dụng cho các bài toán được trình bày bằng tiếng Việt. Đặc biệt, các bài toán thuộc lĩnh vực Xác suất – Thống kê thường đòi hỏi khả năng suy luận logic, phân tích dữ kiện và trình bày lời giải theo các bước rõ ràng.

Mặc dù các mô hình LLM hiện đại có thể tạo lời giải toán học, việc bảo đảm tính chính xác, logic và nhất quán trong trình bày vẫn còn nhiều thách thức. Đồng thời, dữ liệu toán học tiếng Việt, đặc biệt trong lĩnh vực Xác suất – Thống kê, hiện vẫn khá hạn chế. Từ thực tế đó, bài báo tập trung nghiên cứu ứng dụng và tinh chỉnh mô hình ngôn ngữ lớn mã nguồn mở để hỗ trợ tự động hóa giải bài tập Xác suất – Thống kê bằng tiếng Việt, theo hướng tạo lời giải có cấu trúc và dễ giải thích hơn.


1.1. Cơ sở lý thuyết và tổng quan nghiên cứu

Bài toán giải toán từ ngôn ngữ tự nhiên (MWPS) là một hướng nghiên cứu quan trọng trong trí tuệ nhân tạo, xử lý ngôn ngữ tự nhiên và giáo dục thông minh. Mục tiêu của bài toán này là xây dựng hệ thống có khả năng hiểu đề toán viết bằng ngôn ngữ tự nhiên, xác định dữ kiện quan trọng, phân tích quan hệ giữa các đại lượng và lựa chọn công thức phù hợp để đưa ra lời giải. MWPS không chỉ đòi hỏi khả năng tính toán mà còn yêu cầu hiểu ngôn ngữ, suy luận logic và chuyển đổi thông tin từ văn bản sang biểu thức toán học. Trong giáo dục, các hệ thống MWPS có ý nghĩa thực tiễn vì vừa hỗ trợ tìm đáp án, vừa giúp người học hiểu quy trình suy luận, đặc biệt với các bài toán Xác suất – Thống kê có nhiều bước lập luận và yêu cầu trình bày chặt chẽ.

1.1.1 Kiến trúc Transformer

Các mô hình ngôn ngữ lớn hiện đại được xây dựng dựa trên kiến trúc *Transformer*, được đề xuất bởi Vaswani và cộng sự [1]. Khác với các mô hình tuần tự truyền thống như RNN hoặc LSTM, Transformer không xử lý

dữ liệu theo thứ tự thời gian mà cho phép xử lý song song toàn bộ chuỗi đầu vào. Điều này đạt được nhờ cơ chế *self-attention*, giúp mô hình học các mối quan hệ phụ thuộc giữa các token bất kể khoảng cách vị trí trong chuỗi.



Hình 1: Kiến trúc Transformer.

Cốt lõi của Transformer là cơ chế *Scaled Dot-Product Attention*. Trong cơ chế này, mỗi token đầu vào được ánh xạ thành ba vector đặc trưng: *Query (Q)*, *Key (K)* và *Value (V)*. Trực giác của cơ chế này là: với mỗi token (query), mô hình sẽ "hỏi" các token khác trong chuỗi (keys) để xác định mức độ liên quan, từ đó tổng hợp thông tin (values) một cách có trọng số.

Trọng số attention được tính như sau:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Trong đó d_k là kích thước của vector key. Tích vô hướng QK^T biểu diễn mức độ tương đồng giữa các token, giá trị này sau đó được chuẩn hóa bằng hàm *softmax* để tạo thành phân phối xác suất. Hệ số $\frac{1}{\sqrt{d_k}}$ được sử dụng nhằm tránh việc giá trị tích vô hướng trở nên quá lớn khi chiều không gian tăng, giúp ổn định quá trình huấn luyện.

Cơ chế attention cho phép mỗi token có thể "chú ý" đến tất cả các token khác trong chuỗi, từ đó nắm bắt được các phụ thuộc dài hạn mà các mô hình tuần tự truyền thống gặp khó khăn.

Để tăng khả năng biểu diễn, Transformer sử dụng cơ chế *multi-head attention*, cho phép mô hình thực hiện nhiều phép attention song song để học các quan hệ ngữ nghĩa khác nhau. Mỗi khối Transformer còn gồm các lớp

feed-forward network và *positional encoding* nhằm tăng khả năng trích xuất đặc trưng và ghi nhận thứ tự token. Nhờ xử lý song song tốt, nắm bắt hiệu quả phụ thuộc dài hạn và học biểu diễn ngữ nghĩa mạnh, Transformer đã trở thành nền tảng của nhiều mô hình ngôn ngữ lớn hiện đại như GPT, LLaMA, Gemma và DeepSeek.

1.1.2 Tinh chỉnh mô hình với LoRA hoặc QLoRA


Việc huấn luyện lại toàn bộ một mô hình ngôn ngữ lớn (*full fine-tuning*) thường đòi hỏi lượng tài nguyên tính toán và bộ nhớ rất lớn do số lượng tham số có thể lên đến hàng tỷ hoặc hàng chục tỷ. Ngoài ra, quá trình này cũng dễ dẫn đến hiện tượng *overfitting* khi dữ liệu huấn luyện không đủ lớn.

Để khắc phục những hạn chế này, các phương pháp *Parameter Efficient Fine-Tuning (PEFT)* được đề xuất, cho phép tinh chỉnh mô hình bằng cách chỉ cập nhật một phần nhỏ tham số thay vì toàn bộ mô hình. Các phương pháp này giúp giảm đáng kể chi phí tính toán, bộ nhớ và thời gian huấn luyện, đồng thời vẫn duy trì hiệu năng cao.

Một trong những kỹ thuật PEFT phổ biến là *LoRA (Low-Rank Adaptation)* [2]. Ý tưởng cốt lõi của LoRA dựa trên giả định rằng sự thay đổi của ma trận trọng số trong quá trình fine-tuning thường có hạng thấp (*low-rank*). Do đó, thay vì cập nhật trực tiếp ma trận trọng số W , LoRA biểu diễn phần cập nhật dưới dạng tích của hai ma trận hạng thấp:

$$W' = W + BA$$

Trong đó A và B là các ma trận hạng thấp được huấn luyện trong quá trình tinh chỉnh, còn W là trọng số của mô hình nền đã được lượng tử hóa và giữ cố định. Trong quá trình huấn luyện, các tham số gốc W được giữ cố định, chỉ có A và B được cập nhật. Điều này giúp giảm đáng kể số lượng tham số cần tối ưu, từ đó giảm chi phí tính toán và bộ nhớ.



Hình 2: Tinh chỉnh mô hình với LoRA hoặc QLoRA.

Trong kiến trúc Transformer, LoRA thường được áp dụng vào các ma trận trọng số trong cơ chế attention, chẳng hạn như các phép biến đổi tuyến tính của *Query*, *Key* và *Value*. Việc này cho phép mô hình điều chỉnh hành vi attention mà không cần thay đổi toàn bộ mô hình.

So với phương pháp fine-tuning truyền thống, LoRA mang lại nhiều lợi ích: (i) giảm số lượng tham số cần cập nhật, (ii) tiết kiệm bộ nhớ GPU, (iii) cho phép lưu trữ nhiều phiên bản fine-tuned khác nhau trên cùng một mô hình gốc, và (iv) giảm nguy cơ làm suy giảm tri thức đã học trước đó (*catastrophic forgetting*).

QLoRA là một biến thể của LoRA, trong đó mô hình gốc được lượng tử hóa ở độ chính xác thấp, thường là 4-bit, còn các tham số LoRA vẫn được huấn luyện ở độ chính xác cao hơn [3]. Cách tiếp cận này giúp giảm đáng kể yêu cầu bộ nhớ GPU nhưng vẫn duy trì hiệu quả huấn luyện ổn định nhờ các kỹ thuật như *double quantization* và *paged optimizers*. Nhờ đó, QLoRA đạt hiệu năng gần tương đương với full fine-tuning trong

khi chi phí tài nguyên thấp hơn, và cùng với LoRA đã trở thành phương pháp phổ biến để tinh chỉnh các mô hình ngôn ngữ lớn trong điều kiện tài nguyên hạn chế.

1.1.3 Đánh giá mô hình bằng phương pháp LLM-as-a-Judge

Đánh giá các hệ thống sinh văn bản là một thách thức quan trọng trong nghiên cứu các mô hình ngôn ngữ lớn (LLMs), đặc biệt đối với các tác vụ yêu cầu suy luận phức tạp như giải toán. Các chỉ số truyền thống như BLEU hoặc ROUGE chủ yếu đo mức độ tương đồng bề mặt giữa văn bản sinh ra và văn bản tham chiếu, dựa trên sự trùng lặp n-gram. Do đó, các chỉ số này không phản ánh đầy đủ chất lượng của lời giải toán học, vì một lời giải có thể khác về cách diễn đạt nhưng vẫn đúng về mặt logic và kết quả, hoặc ngược lại có thể giống về mặt từ vựng nhưng sai về lập luận.

Đặc biệt, đối với các bài toán Xác suất – Thống kê, chất lượng của lời giải không chỉ phụ thuộc vào đáp án cuối cùng mà còn phụ thuộc vào tính đúng đắn của các bước suy luận trung gian. Vì vậy, cần có một phương pháp đánh giá có khả năng hiểu nội dung và phân tích logic của lời giải.


Để khắc phục hạn chế của các thước đo truyền thống, phương pháp LLM-as-a-Judge đã được đề xuất [4]. Theo cách tiếp cận này, một mô hình ngôn ngữ lớn được sử dụng làm giám khảo để đánh giá lời giải do mô hình khác sinh ra dựa trên đề bài, lời giải tham chiếu và các tiêu chí định sẵn. Phương pháp này có ưu điểm là linh hoạt, hỗ trợ đánh giá nhiều cách giải khác nhau và phản ánh chất lượng lập luận gần với con người hơn. Tuy vậy, kết quả đánh giá vẫn có thể phụ thuộc vào mô hình giám khảo, cách thiết kế prompt và chi phí tính toán. Dù còn hạn chế, LLM-as-a-Judge vẫn là hướng tiếp cận hiệu quả để đánh giá các hệ thống giải toán có suy luận phức tạp.

1.1.4 Kiến trúc nghiên cứu tổng thể

Các đóng góp chính của nghiên cứu bao gồm:

1. Xây dựng bộ dữ liệu bài toán tiếng Việt kèm lời giải chi tiết theo từng bước.
2. Áp dụng phương pháp fine-tuning hiệu quả bằng QLoRA cho mô hình ngôn ngữ lớn.
3. Đề xuất định dạng lời giải có cấu trúc nhằm nâng cao khả năng suy luận và tính minh bạch của đầu ra.
4. Xây dựng pipeline tự động đánh giá kết quả sinh ra của mô hình.

Kiến trúc tổng thể của hệ thống được minh họa trong Hình 3, bao gồm các thành phần chính như tiền xử lý dữ liệu, mô hình LLM được tinh chỉnh và module đánh giá kết quả.



Hình 3: Kiến trúc tổng thể của hệ thống giải bài tập Xác suất – Thống kê sử dụng mô hình ngôn ngữ lớn (LLM).

II. Thiết kế giải pháp và xây dựng mô hình

2.1. Phân tích dữ liệu và tiền xử lý (Data Engineering)

Bộ dữ liệu ban đầu gồm 750 câu hỏi thuộc 5 chủ đề của Xác suất – Thống kê. Nhằm gia tăng số lượng và độ đa dạng của dữ liệu huấn luyện, nhóm đã áp dụng kỹ thuật tăng cường dữ liệu (*Data Augmentation*) với sự hỗ trợ của các mô hình ngôn ngữ lớn như ChatGPT và Gemini. Các phương pháp tăng cường chủ yếu bao gồm:

- Thay thế số liệu trong đề bài trong khi giữ nguyên dạng toán.
- Diễn đạt lại nội dung câu hỏi bằng các cách biểu đạt ngôn ngữ khác nhau nhưng bảo toàn ý nghĩa.
- Tạo lời giải mẫu chi tiết tương ứng cho từng biến thể mới.

Quá trình này giúp mở rộng dữ liệu cả về nội dung số liệu lẫn hình thức diễn đạt, đồng thời vẫn duy trì tính nhất quán về mặt kiến thức. Kết quả, bộ dữ liệu cuối cùng thu được 5.360 mẫu bài toán Xác suất – Thống kê, được tổ chức theo định dạng *instruction–input–output*.

Bảng 1: Các trường trong bộ dữ liệu

STT	Tên cột	Mô tả
1	ID	Mã định danh duy nhất cho mỗi mẫu dữ liệu
2	Instruction	Câu lệnh hướng dẫn cho mô hình (ví dụ: “Hãy giải giúp tôi bài sau:”)
3	Normal Input	Đề bài ở dạng văn bản thuần
4	Latex Input	Đề bài được biểu diễn dưới dạng LaTeX
5	Topic	Chủ đề của bài toán (xác suất cơ bản, phân phối, hồi quy,...)
6	Dạng bài	Phân loại chi tiết dạng bài toán
7	Data_Source	Nguồn dữ liệu (thực tế hoặc sinh tổng hợp)
8	Answer_type	Kiểu đáp án (số, văn bản, bảng,...)
9	Synthetic_type	Loại dữ liệu sinh tổng hợp (nếu có)
10	Response	Lời giải chi tiết từng bước
11	Answer	Đáp án cuối cùng của bài toán

Mỗi mẫu bao gồm câu lệnh hướng dẫn, đề bài ở dạng văn bản thường hoặc LaTeX, nhãn chủ đề, mã dạng bài, lời giải chi tiết và đáp án cuối. Dữ liệu tập trung vào các nhóm nội dung chính như xác suất cơ bản, quy luật phân phối xác suất, biến ngẫu nhiên và phân tích tương quan - hồi quy. Phần lớn mẫu có đáp án dạng số, phù hợp cho bài toán huấn luyện và đánh giá mô hình ngôn ngữ lớn trong tác vụ giải toán tự động.

Quy trình xây dựng dữ liệu bao gồm các bước sau:

- Thu thập các bài toán xác suất và thống kê.
- Chuẩn hóa định dạng câu hỏi và loại bỏ các dữ liệu trùng lặp.
- Xây dựng lời giải chi tiết theo cấu trúc từng bước.
- Chia dữ liệu thành các tập huấn luyện, kiểm tra và đánh giá.

Mỗi mẫu dữ liệu được tổ chức theo định dạng có cấu trúc nhằm giúp mô hình học được quy trình suy luận từng bước và tạo ra lời giải rõ ràng:

```
Câu hỏi: ...
/buoc1: ...
/buoc2: ...
/ketluan: ...
/dapan: ...
```

Ví dụ:

/buoc1 Sử dụng công thức cộng xác suất: $P(AB) = P(A) + P(B) - P(A + B)$. /buoc2 Thay số: $P(AB) = 0.6 + 0.7 - 0.88 = 0.42$. /buoc3 Xét tích xác suất: $P(A) \cdot P(B) = 0.6 \cdot 0.7 = 0.42$. /ketluan Vì $P(AB) = P(A) \cdot P(B) = 0.42$ nên A và B độc lập với nhau. /dapan độc lập

Cách tiếp cận này giúp đảm bảo tính nhất quán trong quá trình sinh lời giải và cải thiện khả năng giải thích của mô hình.

2.2. Thiết kế kiến trúc mô hình (Model Architecture Design)

Trong nghiên cứu này, hai mô hình ngôn ngữ lớn mã nguồn mở là Gemma-7B-it và Qwen2.5-Math được lựa chọn làm mô hình nền để fine-tune và so sánh. Việc lựa chọn hai mô hình này nhằm đại diện cho hai định hướng khác nhau: Gemma-7B-it là mô hình ngôn ngữ đa dụng, trong khi Qwen2.5-Math được thiết kế theo hướng hỗ trợ tốt hơn cho các tác vụ toán học.

Nghiên cứu áp dụng phương pháp QLoRA, một kỹ thuật fine-tuning hiệu quả về tài nguyên, kết hợp giữa lượng tử hóa mô hình và cơ chế cập nhật tham số hạng thấp. Cụ thể, mô hình nền được lượng tử hóa xuống độ chính xác thấp nhằm giảm đáng kể bộ nhớ sử dụng, trong khi các ma trận thích nghi hạng thấp được huấn luyện bổ sung trên một số lớp của mô hình, chủ yếu là các lớp attention.

Một số siêu tham số quan trọng trong quá trình huấn luyện bao gồm:

- QLoRA rank (r)
- QLoRA alpha
- Learning rate
- Batch size
- Số epoch huấn luyện
- Kiểu lượng tử hóa

Việc lựa chọn và điều chỉnh các tham số này có ảnh hưởng đáng kể đến hiệu năng của mô hình sau khi tinh chỉnh. Đồng thời, việc sử dụng QLoRA giúp giảm chi phí tính toán và bộ nhớ, từ đó cho phép huấn luyện các mô hình lớn trên hạ tầng phần cứng có giới hạn mà vẫn duy trì được chất lượng đầu ra ở mức tốt.

2.3. Quy trình huấn luyện và triển khai hệ thống

Quy trình huấn luyện mô hình được thực hiện theo các bước sau:

1. Tiền xử lý dữ liệu và chuyển đổi sang định dạng huấn luyện.
2. Áp dụng phương pháp fine-tuning với QLoRA trên mô hình nền.
3. Huấn luyện mô hình với tập dữ liệu huấn luyện.
4. Đánh giá mô hình trên tập kiểm tra.

Các thư viện phổ biến trong hệ sinh thái học sâu như PyTorch, Hugging Face Transformers và PEFT được sử dụng để triển khai mô hình.

Pipeline tổng thể của hệ thống có thể được mô tả như sau:

Dataset $\rightarrow$ Data preprocessing $\rightarrow$ Fine-tuning (QLoRA) $\rightarrow$ Tuned Model

Sau khi huấn luyện, mô hình được sử dụng trong giai đoạn suy luận (*Inference*) để sinh lời giải cho các bài toán mới.

2.4. Phương pháp đánh giá mô hình

Để đánh giá hiệu năng của mô hình, nghiên cứu sử dụng phương pháp *LLM-as-a-Judge*. Trong phương pháp này, một mô hình LLM khác được sử dụng để đóng vai trò giám khảo nhằm đánh giá chất lượng lời giải của mô hình.

Hệ thống đánh giá xem xét các tiêu chí sau:

- Tính đúng đắn của kết quả mỗi bước tính toán (Math Score)
- Tính logic của các bước suy luận (Logic Score)
- Trung bình điểm (Overall)

Kết quả của mô hình sau khi tinh chỉnh được so sánh với mô hình gốc nhằm đánh giá mức độ cải thiện hiệu năng trong việc giải các bài toán Xác suất – Thống kê.

III. Kết quả và thảo luận

3.1. Thiết lập thí nghiệm

Các thí nghiệm được thực hiện trên nền tảng Google Colab, sử dụng tài nguyên GPU do hệ thống cấp phát trong từng phiên làm việc. Hai mô hình nền được lựa chọn để tinh chỉnh và so sánh là Gemma-7B-it và Qwen2.5-Math. Trong đó, Gemma-7B-it là mô hình ngôn ngữ lớn đa dụng, còn Qwen2.5-Math được thiết kế theo định hướng hỗ trợ tốt hơn cho các tác vụ toán học. Cả hai mô hình đều được fine-tune bằng kỹ thuật QLoRA trên cùng bộ dữ liệu gồm 5.360 mẫu bài toán Xác suất - Thống kê.

Bộ dữ liệu được chia theo tỉ lệ 90% cho tập huấn luyện, 10% cho tập đánh giá và 1 bộ kiểm tra gồm hơn 300 câu hỏi chia đều ra các chủ đề. Các siêu tham số huấn luyện được trình bày trong Bảng 2.

Bảng 2: Siêu tham số huấn luyện

Siêu tham số	Gemma-7B-it	Qwen2.5-Math
LoRA rank (r)	16	16
LoRA alpha	32	32
Learning rate	$2e - 4$	$2e - 4$
Batch size	2 (với 4 bước tích lũy)	2 (với 4 bước tích lũy)
Số epoch	1	1
Optimizer	paged_adamw_32bit	paged_adamw_32bit
Quantization	4-bit (NF4)	4-bit (NF4)

3.2. Phân tích theo nhóm chủ đề

Kết quả đầu ra của mô hình base và sau khi finetune được phân tích theo 5 nhóm chủ đề chính để hiểu rõ thế mạnh của từng mô hình và những khó khăn mô hình đang mắc phải.

Bảng 3: Tỷ lệ chính xác theo nhóm chủ đề

Chủ đề	Qwen (base)	Qwen (FT)	Gemma (base)	Gemma (FT)
Tính xác suất của biến cố	90%	95%	11.11%	73%
Biến ngẫu nhiên và các đặc trưng	16.67%	60%	1.67%	41.67%
Quy luật phân phối xác suất thông dụng	13.64%	89.86%	34.09%	76.81%
Bài toán ước lượng và kiểm định trong thống kê 1 biến	13.64%	61.84%	6.06%	36.16%
Phân tích tương quan và hồi quy trong thống kê 2 biến	10%	25%	0%	17.5%
Trung bình	36.67%	72.46%	10%	54.2%

Kết quả cho thấy fine-tuning cải thiện hiệu năng ở tất cả các nhóm chủ đề và lời giải sinh ra đều tuân thủ cấu trúc giải theo các bước. Qwen2.5-Math đạt kết quả tốt nhất ở nhóm tính xác suất của biến cố và quy luật phân phối xác suất thông dụng. Trong khi đó, cả hai mô hình đều cho kết quả thấp ở nhóm Phân tích tương quan và hồi quy trong thống kê 2 biến, bởi vì dạng bài này thường có dữ liệu đầu vào được trình bày dưới dạng bảng. Điều này làm tăng độ phức tạp trong quá trình xử lý, do mô hình phải đồng thời nhận diện chính xác số liệu, hiểu cấu trúc bảng và xác định mối quan hệ giữa các biến. Vì vậy, khả năng suy luận và đưa ra đáp án chính xác của mô hình ở nhóm bài này còn gặp nhiều hạn chế.

3.3. Đánh giá chất lượng lời giải bằng LLM Judge

Do Qwen2.5-Math sau fine-tuning là mô hình đạt kết quả tốt nhất trên tập kiểm tra, nghiên cứu tiếp tục sử dụng phương pháp *LLM-as-a-Judge* để đánh giá sâu hơn chất lượng lời giải do mô hình này sinh ra.

Bảng 4: Điểm LLM Judge theo nhóm câu trả lời đúng và sai của Qwen2.5-Math sau fine-tuning

Nhóm mẫu	Logic Score	Math Score	Overall
Câu trả lời đúng	9.02	9.24	9.13
Câu trả lời sai	6.28	4.42	5.35

Kết quả cho thấy các câu trả lời đúng có Logic Score và Math Score cao hơn rõ rệt so với nhóm câu trả lời sai. Chênh lệch này cho thấy phương pháp LLM Judge có khả năng phản ánh tương đối tốt chất lượng thực tế của lời giải, không chỉ ở đáp án cuối mà còn ở tính hợp lý của chuỗi suy luận và độ chính xác của các bước tính.

3.4. Thảo luận

Kết quả thực nghiệm cho thấy dữ liệu huấn luyện có cấu trúc đóng vai trò quan trọng trong việc thích nghi mô hình ngôn ngữ lớn với bài toán Xác suất – Thống kê bằng tiếng Việt. Việc tổ chức đầu ra theo các thành phần như `/buoc1`, `/ketluan` và `/dapan` góp phần giúp lời giải rõ ràng hơn và thuận lợi hơn cho quá trình đánh giá.

So sánh giữa hai mô hình cho thấy Qwen2.5-Math phù hợp hơn với các bài toán yêu cầu suy luận và tính toán nhiều bước, trong khi Gemma-7B-it có ưu thế hơn về cách diễn đạt tự nhiên. Bên cạnh đó, phương pháp LLM-as-a-Judge cho phép đánh giá sâu hơn chất lượng lời giải, đặc biệt ở khía cạnh logic và độ chính xác toán học, thay vì chỉ dừng ở mức đối chiếu đáp án cuối.

IV. Kết luận và hướng phát triển

Nghiên cứu này tập trung xây dựng và đánh giá mô hình ngôn ngữ lớn cho bài toán hỗ trợ giải tự luận Xác suất - Thống kê bằng tiếng Việt. Trên cơ sở bộ dữ liệu gồm 5.360 mẫu bài toán có cấu trúc, nghiên cứu đã tiến hành fine-tune hai mô hình nền là Gemma-7B-it và Qwen2.5-Math bằng kỹ thuật QLoRA, đồng thời xây dựng quy trình đánh giá kết quả đầu ra dựa trên cả độ chính xác đáp án và phương pháp LLM-as-a-Judge.

Kết quả thực nghiệm cho thấy fine-tuning trên dữ liệu chuyên biệt mang lại cải thiện rõ rệt cho cả hai mô hình. Trong đó, Qwen2.5-Math sau fine-tuning đạt kết quả tốt hơn, thể hiện ở khả năng sinh lời giải có cấu trúc, mức độ hợp lý trong lập luận và độ chính xác toán học cao hơn trên tập kiểm tra. Bên cạnh đó, nghiên cứu cũng cho thấy việc tổ chức dữ liệu đầu ra theo các thành phần như `/buoc1`, `/ketluan` và `/dapan` có ý nghĩa tích cực trong việc định hướng mô hình sinh lời giải rõ ràng và thuận lợi hơn cho quá trình đánh giá.

Các đóng góp chính của nghiên cứu có thể tóm tắt như sau. Thứ nhất, nghiên cứu đã xây dựng được bộ dữ liệu bài toán Xác suất – Thống kê bằng tiếng Việt có cấu trúc, phục vụ cho bài toán fine-tune mô hình ngôn ngữ lớn. Thứ hai, nghiên cứu đã triển khai và so sánh hai hướng mô hình nền khác nhau, qua đó chỉ ra ưu thế của mô hình có định hướng toán học trong tác vụ giải toán tự luận. Thứ ba, nghiên cứu đề xuất cách kết hợp giữa đánh giá đáp án cuối và đánh giá chất lượng lời giải bằng LLM Judge, giúp việc phân tích kết quả không chỉ dừng ở mức đúng – sai mà còn xem xét được tính logic và độ chính xác trong các bước giải.

Tuy nhiên, nghiên cứu vẫn còn một số hạn chế. Quy mô dữ liệu chưa đủ lớn để bao phủ toàn bộ các dạng bài phức tạp trong Xác suất – Thống kê. Một số nhóm bài như tương quan và hồi quy vẫn cho kết quả thấp, cho thấy mô hình chưa xử lý tốt các bài toán yêu cầu nhiều bước suy luận và diễn giải thống kê. Ngoài ra, đầu ra của mô hình vẫn chưa hoàn toàn ổn định về định dạng trong mọi trường hợp, và kết quả đánh giá bằng LLM

Judge vẫn cần được kết hợp với các tiêu chí đối sánh khách quan để tăng độ tin cậy.

Trong thời gian tới, nghiên cứu có thể được phát triển theo một số hướng. Trước hết, cần mở rộng và cân bằng lại bộ dữ liệu, đặc biệt ở các nhóm bài khó và các dạng bài còn ít mẫu. Tiếp theo, có thể cải thiện cơ chế kiểm soát đầu ra nhằm tăng mức độ tuân thủ định dạng lời giải và hạn chế sinh thừa nội dung sau đáp án cuối. Ngoài ra, việc kết hợp thêm các phương pháp đánh giá dựa trên luật đối sánh, chuẩn hóa đáp án và đánh giá theo từng mức độ khó của bài toán sẽ giúp kết quả thực nghiệm chặt chẽ hơn. Về lâu dài, nghiên cứu có thể mở rộng sang các bài toán toán học khác bằng tiếng Việt, hoặc phát triển thành hệ thống hỗ trợ học tập có khả năng giải thích lời giải một cách trực quan và nhất quán hơn cho người học.

Tài liệu

- [1] Vaswani, A., Shazeer, N., Parmar, N., et al., *Attention Is All You Need*, Advances in Neural Information Processing Systems (NeurIPS), 2017.
- [2] Hu, E. J., Shen, Y., Wallis, P., et al., *LoRA: Low-Rank Adaptation of Large Language Models*, International Conference on Learning Representations (ICLR), 2022.
- [3] Dettmers, T., Pagnoni, A., Holtzman, A., Zettlemoyer, L., *QLoRA: Efficient Finetuning of Quantized LLMs*, NeurIPS, 2023.
- [4] Zheng, L., Chiang, W., Sheng, Y., et al., *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*, NeurIPS, 2023.
- [5] Touvron, H., Martin, L., Stone, K., et al., *LLaMA: Open and Efficient Foundation Language Models*, Meta AI Research, 2023.
- [6] Gemma Team, *Gemma: Open Models Based on Gemini Research and Technology*, Google DeepMind, 2024.
- [7] Gao, L., Madaan, A., Zhou, S., et al., *PAL: Program-Aided Language Models*, ICML, 2023.
- [8] Houlsby, N., Giurgiu, A., Jastrzebski, S., et al., *Parameter-Efficient Transfer Learning for NLP*, ICML, 2019.
- [9] Ouyang, L., Wu, J., Jiang, X., et al., *Training Language Models to Follow Instructions with Human Feedback*, NeurIPS, 2022.
- [10] Li, Y., Chiang, W., Sheng, Y., et al., *MT-Bench: Evaluating Large Language Models in Multi-turn Dialogue*, 2023.
- [11] Wei, J., Wang, X., Schuurmans, D., et al., *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*, NeurIPS, 2022.
- [12] Wang, X., Wei, J., Schuurmans, D., et al., *Self-Consistency Improves Chain of Thought Reasoning in Language Models*, ICLR, 2023.
- [13] Cobbe, K., Kosaraju, V., Bavarian, M., et al., *Training Verifiers to Solve Math Word Problems*, arXiv preprint arXiv:2110.14168, 2021.